

Титульный лист материалов по дисциплине
(заполняется по каждому виду учебного материала)

ДИСЦИПИНА	Проектирование и обучение нейронных сетей <small>(полное наименование дисциплины без сокращений)</small>
ИНСТИТУТ	Информационные технологии
КАФЕДРА	Вычислительная техника <small>полное наименование кафедры</small>
ВИД УЧЕБНОГО МАТЕРИАЛА	Лекция <small>(в соответствии с пп.1-11)</small>
ПРЕПОДАВАТЕЛЬ	Сорокин Алексей Борисович <small>(фамилия, имя, отчество)</small>
СЕМЕСТР	7 семестр, 2023/2024 <small>(указать семестр обучения, учебный год)</small>

13. ЛЕКЦИЯ. Сверточные сети

Биологическая мотивация

Идея сверточных нейронных сетей во многом мотивирована исследованиями о зрительной коре головного мозга. Человек с легкостью решает довольно сложные задачи распознавания образов, он без видимых усилий различает тысячи объектов, составляющих его окружение, несмотря на изменение расстояния, ракурса, перспективы и освещения.

При этом человечество давно задумывались о том, как именно устроено зрение. Глаз как оптический прибор изучали Леонардо да Винчи, Иоганн Кеплер и многие другие великие физики, отмечавшие его выдающиеся оптические свойства.

Однако с точки зрения устройства сверточных нейронных сетей научный интерес представляет процесс, который происходит с прочитанным с сетчатки изображением.

Зрительный нерв (рис.2) – толстый пучок аксонов ганглионарных клеток, по которому информация с сетчатки доходит до мозга, – отмечали еще средневековые анатомы, и его важность для зрения была очевидной.



Рис.2. Строение зрительного нерва

Зрительный нерв входит в таламус, отдел мозга, обрабатывающий информацию от органов чувств, там первичная обработка происходит в так называемом латеральном колленчатом теле, а затем зрительная информация поступает в собственно зрительную кору (рис.3).




Рис.3. Мозг человека, вид сзади. Красным цветом обозначено первичная зрительная кора; оранжевым и жёлтым —экстрастриарная зрительная кора.

Зрительная кора расположена сзади, в затылочной доле головного мозга. Понятие зрительная кора включает первичную зрительную кору (также называемую зрительной зоной V1) и экстрастриарную зрительную кору – зоны V2, V3, V4, V5. Иногда выделяют зоны V6 и V7. Зоны отличаются друг от друга физиологией, архитектурой, обособленным положением в коре, и несомненно они различаются и по своим функциям. Хотя на самом деле функциональная специализация зон пока что до конца не ясна, но по нынешнему представлению [2]:

V1 – в этой зоне выделяются локальные признаки небольших участков считанного с сетчатки изображения;

V2 – продолжает выделять локальные признаки, слегка обобщая их и добавляя бинокулярное зрение (то есть стереоэффект от двух глаз);

V3 – зона распознается цвет, текстуры объектов, появляются первые результаты их сегментации и группировки;

V4 – распознает геометрические фигуры и очертания объектов, пока несложных; кроме того, именно здесь наиболее сильна модуляция посредством нашего внимания: активация нейронов в V4 не равномерна по всему полю зрения, а сильно зависит от того, на что мы осознанно или неосознанно обращаем внимание;

V5 – в основном занимается распознаванием движений, пытаюсь понять, куда и с какой скоростью передвигаются в зоне видимости те самые объекты, очертания которых выделились в зоне V4;

V6 – зона обобщает данные о всей картинке, она реагирует на изменения по всему полю зрения и изменения в картинке вследствие того, что передвигается сам человек;

V7 – в зоне происходит распознавание сложных объектов, в частности человеческих лиц.

Такая функциональная специализация – это первое замечание о зрительной коре, которое соответствует глубоким нейронным сетям: более высокие уровни нужны для того, чтобы выделять более общие признаки, соответствующие абстрактным свойствам входа, а на нижних уровнях признаки более конкретные. В сверточных сетях эффект будет тот же самый. Но есть и другие интересные свойства архитектуры зрительной коры, которые нашли отражение в машинном обучении.

При этом среди перечисленных зон иерархия не такая уж строгая: есть масса прямых связей, когда, например, нейроны из зоны V1 подаются на вход не

только в зону V2, но и напрямую в зону V5; это находит отражение в сверточных архитектурах.

При этом между нейронами в мозге всегда присутствует очень сильная обратная связь от более высоких уровней к более низким. Например, современные исследования предполагают, что внимание, которое зарождается в зоне V4, потом переходит обратно к зонам V2 и V1, где также присутствует сильная модуляция на основе зрительного представления.

В искусственных нейронных сетях тоже вводят подобные механизмы. Однако в машинном обучении обратная связь находится на «низком» уровне, пока нет математической модели на подобии мозга управлять ею – одна из важнейших открытых задач нейробиологии. Пока многими специализациями искусственные нейронные сети не снабжены.

Из всей зрительной коры наиболее хорошо изучена зона V1, первичная зрительная кора: она ближе всего к собственно входам, достаточно просто устроена, и там проще понять, за что «отвечают» отдельные нейроны и как они друг с другом взаимодействуют; именно с зоной V1 были связаны самые значительные результаты. Зона V1 состоит из шести уровней нейронов, которые распознают [2]:

- *ориентацию*, то есть нейрон реагирует, например, на то, что освещенность вдоль диагонали изображения высокая, а по двум другим углам низкая; или на то, что освещенность нижней части изображения выше, чем верхней; таким образом нейроны распознают границы изображений;
- *пространственную частоту*, то есть то, насколько часто меняется освещенность в пределах рецептивного поля нейрона;
- *направление*: человеку интересна не только и не столько статичная картинка, сколько происходящие в ней движения; нейроны умеют «запоминать» и сравнивать предыдущие входы с последующими, распознавая таким образом направление не только в пространстве, но и во времени; аналогично распознается и временная частота;
- *различие между глазами*: в V1 у каждого нейрона два рецептивных поля, для каждого глаза, распознают различия между тем, что видят левый и правый глаз;
- *цвет*, относительно которого нейроны обычно распознают одно из трех основных направлений: красный – зеленый, синий – желтый и черный – белый.

Видно, обработка изображений в мозге человека устроена как глубокая нейронная сеть. И так только зоне V1 выделяют шесть уровней, а ведь сигнал по

ходу движения проходит через сразу несколько зон, начиная с латерального коленчатого тела (в котором, кстати, тоже шесть уровней) и заканчивая высокоуровневыми зонами V6 и V7. Это нашло отражение в сверточных нейронных сетях для обработки изображений — это самые глубокие из существующих сетей.

Изображение

Обычно цветные картинки, подающиеся на вход нейронной сети, представлены в виде нескольких прямоугольных матриц, каждая из которых задает уровень одного из цветовых каналов в каждом пикселе изображения (рис. 3).




Рис. 3. Растровое изображение

Например, картинка размером 200×200 пикселей — это 120 000 чисел, три матрицы интенсивностей размером 200×200 каждая. Если изображение черно-белое, как, например, в MNIST (Modified National Institute of Standards and Technology — объёмная база данных образцов рукописного написания цифр.), то такая матрица будет одна. А если это не простая картинка, а, скажем, результат изображающей масс-спектрометрии, когда в каждом пикселе находится целый спектр, то матриц может быть очень много. Но в любом случае мы будем предполагать, что в каждом пикселе входного изображения стоит некоторый тензор (обычно одномерный, то есть вектор чисел), и его компоненты называются каналами.

Все современные системы машинного обучения используют тензоры в качестве основной структуры данных. При этом тензоры являются фундаментальной структурой данных — настолько фундаментальной, что это отразилось на названии библиотеки Google TensorFlow [3].

Фактически тензор — это контейнер для данных, практически всегда числовых. Другими словами, это контейнер для чисел. Вы уже знакомы с матрицами, которые являются двумерными тензорами: тензоры — это обобщение матриц с произвольным количеством измерений (обратите внимание, что в терминологии тензоров измерения часто называют осями).

Приведем примеры тензоров [3]:

- Скаляр (тензором нулевого ранга) – тензор, содержащий единственное число. Количество осей тензора также называют его рангом.
- Вектор (тензор первого ранга) – одномерный массив чисел. Тензор первого ранга имеет единственную ось.
- Матрица (тензор второго ранга) – массив векторов. Матрица имеет две оси (часто их называют строками и столбцами). Матрицу можно представить, как прямоугольную таблицу с числами.
- Тензоры третьего и высшего рангов – упакованные матрицы в новый массив, то получится трехмерный тензор. Упаковав трехмерные тензоры в массив, получится четырехмерный тензор и т. д. В глубоком обучении чаще всего используются тензоры от нулевого ранга до четырехмерных, но иногда, например, при обработке видеоданных, дело может дойти и до пятимерных тензоров.

Данные, которыми приходится манипулировать, почти всегда будут относиться к одной из следующих категорий: векторные данные – двумерные тензоры с формой (*образцы, признаки*); временные ряды или последовательности – трехмерные тензоры с формой (*образцы, метки_времени, признаки*); изображения – четырехмерные тензоры с формой (*образцы, высота, ширина, цвет*) или с формой (*образцы, цвет, высота, ширина*); видео — пятимерные тензоры с формой (*образцы, кадры, высота, ширина, цвет*) или с формой (*образцы, кадры, цвет, высота, ширина*).

Изображения имеют три измерения: высоту, ширину и цвет. Даже при том, что черно-белые изображения (как в наборе данных MNIST) имеют только один канал цвета и могли бы храниться в двумерных тензорах, по соглашениям тензоры с изображениями всегда имеют три измерения, где для черно-белых изображений отводится только один канал цвета. Соответственно, пакет со 128 черно-белыми изображениями, имеющими размер 256×256 , можно сохранить в тензоре с формой (128, 256, 256, 1), а пакет со 128 цветными изображениями – в тензоре с формой (128, 256, 256, 3) (рис. 4).




Рис. 4. Четырехмерный тензор с изображениями
(в соответствии с соглашением «канал следует первым»)

В отношении форм тензоров с изображениями существует два соглашения: соглашение канал следует последним (используется в TensorFlow) и соглашение канал следует первым (используется в Theano). Фреймворк машинного обучения TensorFlow, разработанный компанией Google, отводит для цвета последнюю ось: (образцы, высота, ширина, цвет). А библиотека Theano отводит для цвета ось, следующую сразу за осью пакетов: (образцы, цвет, высота, ширина). Если следовать соглашению, принятому в Theano, предыдущие примеры тензоров будут иметь форму (128, 1, 256, 256) и (128, 3, 256, 256). Фреймворк Keras поддерживает оба формата.

Операция свертки

Сверточная нейронная сеть, предложенная Яном Лекуном (LeCun) в 1988 – это специальный вид нейронной сети для обработки данных с сеточной топологией. Однако справедливости ради надо сказать, что первой настоящей сверточной сетью, позаимствовавшей для информатики воплощенные природой в зрительной коре идеи, был неоконитрон Кунихико Фукусимы, появившийся в 1979–1980 годах. Впрочем, Фукусима не использовал градиентный спуск и вообще обучение с учителем, а его работы были довольно прочно забыты.

Основная идея сверточной сети состоит в том, что обработка участка изображения очень часто должна происходить независимо от конкретного расположения этого участка. Эта ключевая идея наделяет сверточные нейронные сети двумя важными свойствами [4]:

1. Шаблоны, которые они изучают, являются инвариантными (неизменными) в отношении переноса. После изучения определенного шаблона в правом нижнем углу картинке сверточная нейронная сеть сможет распознавать его повсюду: например, в левом верхнем углу. Полносвязной сети пришлось бы изучить шаблон заново, если он появляется в другом месте. Это

увеличивает эффективность сверточных сетей в задачах обработки изображений (потому что видимый мир по своей сути является инвариантным в отношении переноса): таким сетям требуется меньше обучающих образцов для получения представлений, обладающих силой обобщения.

2. Они могут изучать пространственные иерархии шаблонов (рис. 5). Первый сверточный слой будет изучать небольшие локальные шаблоны, такие как края, второй – более крупные шаблоны, состоящие из признаков, возвращаемых первым слоем, и т. д. Это позволяет сверточным нейронным сетям эффективно изучать все более сложные и абстрактные визуальные представления (потому что видимый мир по своей сути является пространственно-иерархическим).




Рис. 5. Видимый мир формируется пространственными иерархиями видимых модулей.

На рис.5 гиперлокальные края объединяются в локальные объекты, такие как глаза или уши, которые, в свою очередь, объединяются в понятия еще более высокого уровня, такие как «кошка»

Свертка — это всего лишь линейное преобразование входных данных особого вида. Если x^l — карта признаков в слое под номером l , то результат двумерной свертки с ядром размера $2d + 1$ и матрицей весов W размера $(2d + 1) \times (2d + 1)$ на следующем слое будет таким [4]:

$$y_{i,j}^l = \sum_{-d \leq a, b \leq d} W_{a,b} x_{i+a, j+b}^l$$

где $y_{i,j}^l$ — результат свертки на уровне l , а $x_{i,j}^l$ — ее вход, то есть выход всего предыдущего слоя. Иначе говоря, чтобы получить компоненту (i, j) следующего уровня, применяется линейное преобразование к квадратному окну

предыдущего уровня, то есть скалярно умножаем пиксели из окна на вектор свертки. На рис. 6 приведен пример свертки в применении к двумерному тензору.




Рис. 6. Пример двумерной свертки.

На рис.6. выход ограничен только теми позициями, для которых ядро целиком укладывается в изображение; в некоторых контекстах такая свертка называется «допустимой». Прямоугольник с указывающими на него стрелками показывает, как левый верхний элемент выходного тензора образуется путем применения ядра к соответствующей левой верхней области входного тензора.

Приведем более конкретный пример, применим свертку с матрицей весов W размера 3×3 к матрице X размера 5×5 . Операция свертки обычно обозначается звездочкой $*$

$$\begin{pmatrix} 0 & 1 & 2 & 1 & 0 \\ 4 & 1 & 0 & 1 & 0 \\ 2 & 0 & 1 & 1 & 1 \\ 1 & 2 & 3 & 1 & 0 \\ 0 & 4 & 3 & 2 & 0 \end{pmatrix} * \begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 2 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 9 & 5 & 4 \\ 8 & 8 & 10 \\ 8 & 15 & 12 \end{pmatrix}$$

Умножение подматрицы исходной матрицы X , соответствующей окну, и матрицы весов W – это не умножение матриц, а просто скалярное произведение соответствующих векторов. А всего окно умещается в матрице X девять раз, и получается (рис.7).




Рис. 7. Пример подсчета результата свертки: два примера подматрицы и общий результат

В терминологии сверточных сетей первый аргумент (в нашем примере функция X) называется входом, а второй (функция W) – ядром. Выход иногда называют картой признаков.

Если размер свертки будет выражаться четным числом, то в одном из случаев в пределах суммирования неравенство станет строгим. Это преобразование обладает следующими свойствами [1]:

- свертка сохраняет структуру входа (порядок в одномерном случае, взаимное расположение пикселей в двумерном и т.д.), так как применяется к каждому участку входных данных в отдельности;
- операция свертки обладает свойством разреженности, так как значение каждого нейрона очередного слоя зависит только от небольшой доли входных нейронов (а, например, в полносвязной нейронной сети каждый нейрон зависел бы от всех нейронов предыдущего слоя);
- свертка многократно переиспользует одни и те же веса, так как они повторно применяются к различным участкам входа.

Почти всегда после свертки в нейронной сети следует нелинейность, которая записывается следующим образом:

$$z_{i,j}^l = h(y_{i,j}^l).$$

В качестве функции h часто используют ReLU, особенно в очень глубоких сетях, но и классические гиперболические функции также используются.

Свойство разреженной связностью (разреженными весами) достигается это за счет того, что ядро меньше входа. Например, входное изображение может содержать тысячи или миллионы пикселей, но небольшие значимые признаки. Например, границы, можно обнаружить с помощью ядра, охватывающего всего десятки или сотни пикселей. Следовательно, нужно хранить меньше параметров, а это снижает требования модели к объему памяти и повышает ее статистическую эффективность. Кроме того, для вычисления выхода потребуется меньше операций. Все вместе обычно намного повышает

эффективность сети [1].

Графически разреженная связность иллюстрируется на рис. 8.




Рис. 8. Разреженная связность.

На рис.8. выделен один входной блок x_3 и выходные блоки в слое s , на которые этот блок влияет. Вверху. Если s образован сверткой с ядром ширины 3, то x_3 влияет только на три выхода. Внизу. Если s образован умножением на матрицу, то связность уже не разреженная, поэтому x_3 влияет на все выходы. В глубокой сверточной сети блоки нижних уровней могут косвенно взаимодействовать с большей частью сети, как показано на рис. 9. Это дает сети возможность эффективно описывать сложные взаимодействия между многими переменными путем составления из простых строительных блоков, каждый из которых описывает только разреженные взаимодействия [1].




Рис. 9. Рецептивное поле блоков в глубоких слоях сверточной сети больше рецептивного поля в слоях, близких к поверхности.

Этот эффект усиливается, если сеть включает такие архитектурные особенности. Это означает, что прямые связи в сверточной сети действительно

очень разрежены, блоки в глубоких слоях могут быть косвенно связаны со всем входным изображением или с большей его частью.

Под разделением параметров понимают, что один и тот же параметр используется в нескольких функциях модели. В традиционной нейронной сети каждый элемент матрицы весов используется ровно один раз при вычислении выхода слоя. Он умножает на один элемент входа, и больше мы к нему никогда не возвращаемся. Вместо употребления термина «разделение параметров» можно сказать, что в сети присутствуют **связанные веса**, поскольку значение веса, примененного к одному входу, связано со значением веса, примененного где-то еще. В сверточной нейронной сети каждый элемент ядра применяется к каждой позиции входа (за исключением, быть может, некоторых граничных пикселей – в зависимости от того, как решено обрабатывать границу). Разделение параметров означает, что вместо обучения отдельного набора параметров для каждой точки мы должны обучить только один набор [5].

Таким образом, свертка многократно эффективнее умножения матриц с точки зрения требований к памяти и статистической эффективности. Механизм разделения параметров наглядно изображен на рис. 10, где черными стрелками показаны связи, в которых участвует конкретный параметр в двух разных моделях. Вверху. Черными стрелками показано использование центрального элемента 3-элементного ядра в сверточной модели. Благодаря разделению параметров этот параметр используется для всех элементов входа. Внизу. Одиночная черная стрелка показывает использование центрального элемента матрицы весов в полносвязной модели. Здесь никакого разделения параметров нет, поэтому параметр используется только один раз [1].




Рис. 10. Разделение параметров.

Практическое применение принципов (разреженная связность и

разделение параметров) кардинально улучшают эффективность линейной функции при обнаружении границ в изображении.

В случае свертки специальный вид разделения параметров наделяет слой свойством, которое называется эквивариантностью относительно параллельного переноса. При работе с изображениями свертка создает двумерную карту появления определенных признаков во входном изображении. Если переместить объект во входном изображении, то его представление на выходе переместится на такую же величину. Это бывает нужно, когда мы знаем, что некоторая функция от небольшого числа пикселей полезна при применении к нескольким участкам входа. Иногда, в случае обработки изображений полезно обнаруживать границы в первом слое сверточной сети. Одни и те же границы встречаются более-менее везде в изображении, поэтому имеет смысл разделять параметры по всему изображению. Но в некоторых случаях такое глобальное разделение параметров нежелательно. Например, если обрабатываются изображения, которые были кадрированы, так чтобы в центре оказалось лицо человека, то, наверное, хотелось выделять разные признаки в разных точках – часть сети будет обрабатывать верхнюю часть лица в поисках бровей, а другая часть – искать подбородок в нижней части лица.

Свертка не эквивариантна относительно некоторых преобразований, например, масштабирования или поворота. Для обработки таких преобразований нужны другие механизмы. Существуют типы данных, которые нельзя обработать с помощью нейронных сетей, определяемых путем умножения на матрицу фиксированной формы. Свертка позволяет обрабатывать некоторые данные такого рода.

Эффекты границ, дополнение и шаг свертки

При обсуждении свертки в контексте нейронных сетей обычно имеется в виду не стандартная операция дискретной свертки в том смысле, в каком она понимается с математической точки зрения. Практически используемые функции немного отличаются. Опишем эти различия и выделим некоторые полезные свойства функций, применяемых в нейронных сетях. Прежде всего, под сверткой в нейронных сетях понимается операция, состоящая из многих параллельных вычислений свертки (рис. 11).

Примечательно, что выходные ширина и высота могут отличаться от входных. На то есть две причины [4]:

- эффекты границ, которые могут устраняться дополнением входной карты признаков;
- использование шага свертки.

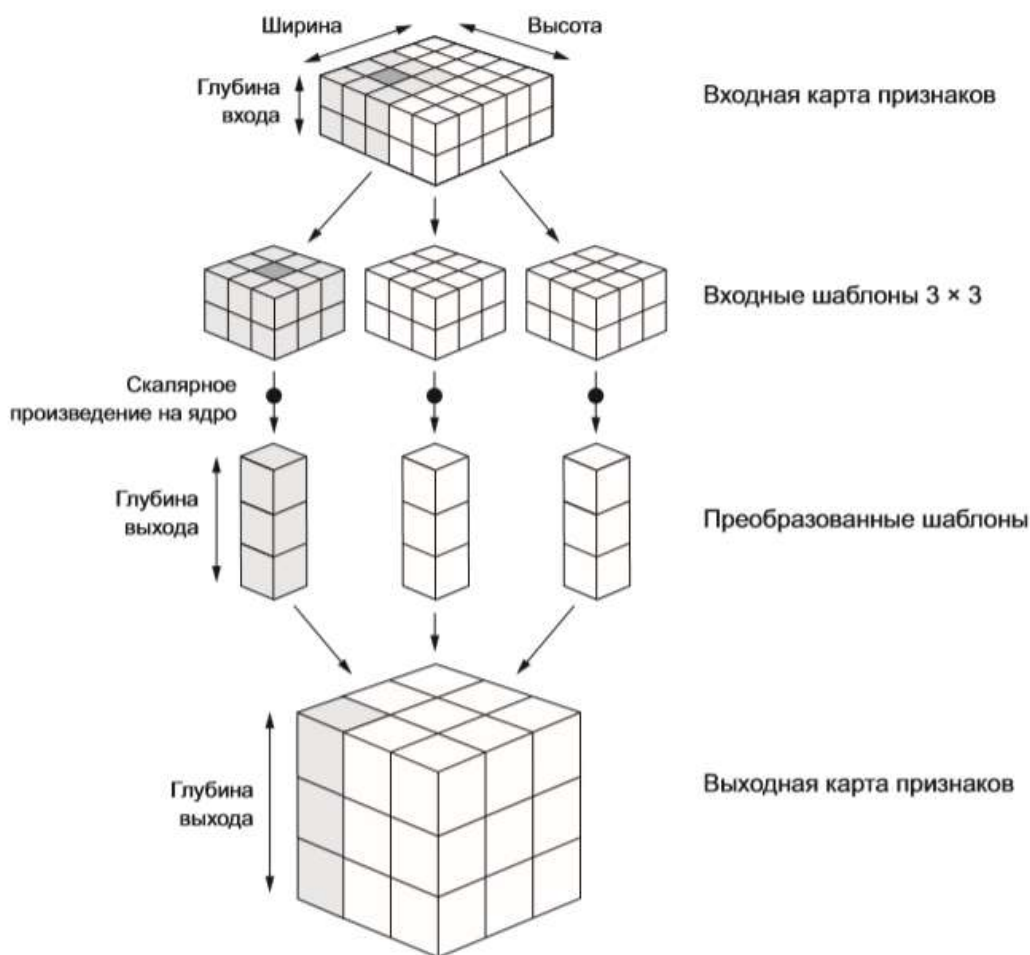


Рис. 11. Принцип действия свертки

Раскроем более подробно эти понятия.

Рассмотрим карту признаков 5×5 (всего 25 клеток). Существует всего 9 клеток, в которых может находиться центр окна 3×3 , образующих сетку 3×3 (рис. 12). Следовательно, карта выходных признаков будет иметь размер 3×3 . Она получилась сжатой: ровно на две клетки вдоль каждого измерения.




Рис. 12. Допустимые местоположения шаблонов 3×3 во входной карте признаков 5×5

Чтобы получить выходную карту признаков с теми же пространственными размерами, что и входная карта, можно использовать дополнение. Это важное свойство любой реализации сверточной сети – возможность неявно дополнять

нулями вход V , чтобы расширить его (рис.13).




Рис. 13. Влияние дополнения нулями на размер сети.

Без этого ширина представления уменьшается на ширину ядра без одного пикселя в каждом слое. Дополнение входа нулями позволяет управлять шириной ядра и размером выхода независимо. Отсутствие дополнения, принуждает выбирать между быстрым уменьшением пространственной протяженности сети и использованием малых ядер – то и другое значительно ограничивает выразительную мощность сети.

Дополнение заключается в добавлении соответствующего количества строк и столбцов с каждой стороны входной карты признаков, чтобы можно было поместить центр окна свертки в каждую входную клетку [5]. Для окна 3×3 нужно добавить один столбец справа, один столбец слева, одну строку сверху и одну строку снизу. Для окна 5×5 нужно добавить две строки (рис. 14).




Рис. 14. Дополнение входной карты признаков 5×5 , чтобы получить 25 шаблонов 3×3

Заслуживают упоминания три частных случая дополнения нулями. Первый называется корректной сверткой – когда дополнение не используется вовсе, а ядру свертки разрешено занимать только те позиции, где ядро целиком уместается внутри изображения.. В таком случае каждый выходной пиксель

является функцией одного и того же числа входных, поэтому поведение выходных пикселей несколько более регулярно. Но размер выхода при этом уменьшается на каждом слое. Если ширина входного изображения равна m , а ширина ядра – k , то ширина выхода будет равна $m - k + 1$. Скорость такого сжатия может быть очень велика, если используются большие ядра. Поскольку сжатие больше 0, число сверточных слоев в сети ограничено. По мере добавления слоев пространственная протяженность сети рано или поздно снизится до 1×1 , после чего новые слои нельзя считать сверточными.

Другой частный случай называется конгруэнтной сверткой – дополнение столькими нулями, чтобы размер выхода был равен размеру входа. В этом случае сеть может содержать столько сверточных слоев, сколько может поддерживать оборудование, поскольку операция свертки не изменяет архитектурных возможностей следующего слоя. Однако входные пиксели в окрестности границы оказывают меньшее влияние на выходные, чем пиксели, расположенные ближе к центру. Из-за этого граничные пиксели будут недостаточно представлены в модели.

Этот недостаток послужил основанием для еще одного крайнего случая, называемого полной сверткой, когда добавляется столько нулей, чтобы каждый пиксель посещался k раз в каждом направлении. В результате размер выходного изображения становится равен $m + k - 1$. В таком случае выходные пиксели вблизи границы являются функциями меньшего числа входных пикселей, чем пиксели в центре. Из-за этого трудно обучить единственное ядро, которое вело бы себя хорошо во всех позициях сверточной карты признаков. Обычно оптимальная степень дополнения нулями лежит между «корректной» и «конгруэнтной» сверткой.

Другой фактор, который может влиять на размер выходной карты признаков, – шаг свертки. В объяснениях предполагалось, что центральная клетка окна свертки последовательно перемещается в смежные клетки входной карты. Однако в общем случае расстояние между двумя соседними окнами является настраиваемым параметром, который называется шагом свертки и по умолчанию равен 1. Также имеется возможность определять свертки с пробелами (strided convolutions) – свертки с шагом больше 1. На рис. 15 можно видеть, как извлекаются шаблоны 3×3 сверткой с шагом 2 из входной карты 5×5 (без дополнения) [5].




Рис. 15. Шаблоны 3×3 свертки с шагом 2×2

Использование шага 2 означает уменьшение ширины и высоты карты признаков за счет уменьшения разрешения в два раза (в дополнение к любым изменениям, вызванным эффектами границ). Таким образом, будем называть s шагом свертки пониженного разрешения. Можно также определить разные шаги по каждому направлению движения (рис. 16) [4].

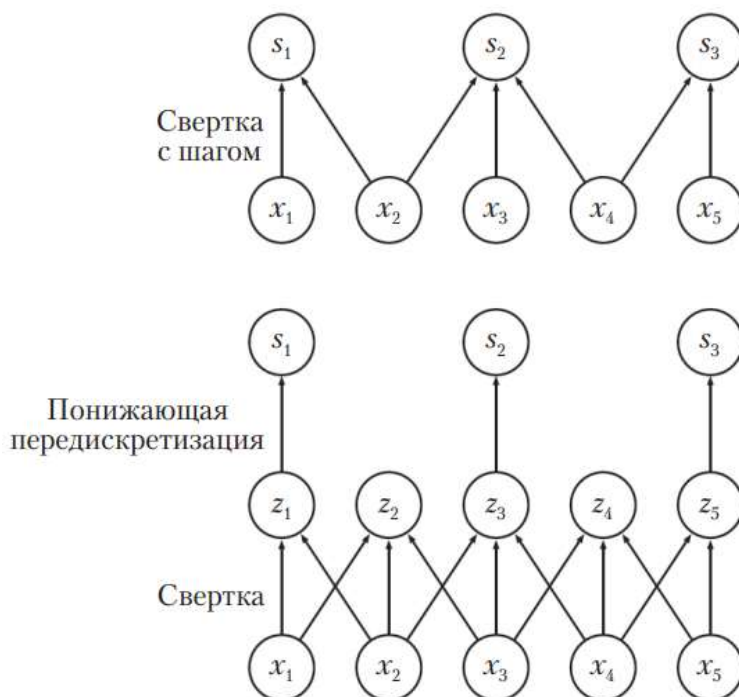


Рис. 16. Свертка с шагом.

В этом примере шаг равен 2. (Вверху) Свертка с шагом 2, реализованная в виде одной операции. (Внизу) Свертка с шагом больше 1 пикселя математически эквивалентна свертке с шагом 1, за которой следует понижающая передискретизация. Очевидно, что такой двухэтапный подход вычислительно расточителен, поскольку многие вычисленные значения затем отбрасываются.

Свертки с пробелами редко используются на практике, хотя могут пригодиться в моделях некоторых типов, поэтому желательно знать и помнить об этой возможности.